

ELMÉLETI INFORMATIKA

I. rész

Formális nyelvek és automaták

Bevezetés, alapfogalmak

1. előadás

Bevezetés

A számítógépek programozására használatos **mesterséges nyelvek** sokkal egyszerűbbek a természetes nyelveknél.

Egy ilyen mesterséges nyelv jellemzői:

- a fogalmi kör erősen leszűkített,
- a szókincs szegényes,
- a nyelvtani szabályok egyszerűek,
- a szabályhalmazban nincsenek kivételek.

Bevezetés

Programozási nyelvek esetén igen fontos feladat pontosan definiálni azokat a **forráskódokat** (**programokat**), amelyeket az adott programozási nyelvben megírva **helyes**nek tekintünk.

Ez a probléma leginkább egy **fordítóprogram** (**compiler**) megtervezése során merül fel, amely egy magasabb szintű programozási nyelven megírt **forráskód**ból egy alacsonyabb szintű, ún. **tárgykód**ot állít elő. A fordítóprogram ugyanis első lépésben megvizsgálja, hogy a lefordítandó forráskód helyes-e, és csak azután fordítja le azt.

Bevezetés

Programozási nyelvek esetén igen fontos feladat pontosan definiálni azokat a **forráskódokat** (**programokat**), amelyeket az adott programozási nyelvben megírva **helyes**nek tekintünk.

Kérdés: Mikor helyes egy forráskód?

Válasz: Ha teljesít bizonyos előre meghatározott szabályokat, feltételeket.

Például:

- megadott kulcsszóval (pl. **program**) kezdődik,
- előre megadott kulcsszavak használhatók benne előre megadott szabályok szerint,
- a program végén egy megadott jel (pl. **.**) szerepel,
- stb.

Szintaxis

Egy programozási nyelv esetén azon szabályok, feltételek összessége, amelyek segítségével definiálható, hogy az adott programozási nyelvben megírt forráskód mikor tekinthető **helyes**nek.

Ha egy program teljesíti a szintaxisban megadott szabályokat, feltételeket, akkor a program **szintaktikailag helyes**.

Kérdés: Hogyan adható meg egy programozási nyelv szintaxisa?

Válasz: Legelterjedtebb a **generatív nyelvtannal** történő szintaxis megadás.

1.1 példa: (egy aritmetikai kifejezés szintaxisának megadása)

- 1) Első lépésben meg kell adnunk, hogy milyen **szimbólumok** (számok, *betűk*, *műveleti jelek* stb.) szerepelhetnek a definiálandó aritmetikai kifejezésekben:

Változók: $A \ B \ C \ D$

Konstansok: 0 1 2 3 4 5 6 7 8 9

Műveleti jelek: $+ \ * \ (\)$

$A * B + (D + 2 * A)$

ez aritmetikai kifejezés

$A) * BCC(** + 3$

ez nem aritmetikai kifejezés

1.1 példa: (egy aritmetikai kifejezés szintaxisának megadása)

2) Meg kell adni, hogy a már megadott szimbólumokból milyen szabályok alapján épülnek fel az aritmetikai kifejezések:

$\langle \text{KIFEJEZÉS} \rangle \rightarrow \langle \text{TAG} \rangle$

$\langle \text{KIFEJEZÉS} \rangle \rightarrow \langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle$

$\langle \text{TAG} \rangle \rightarrow \langle \text{FAKTOR} \rangle$

$\langle \text{TAG} \rangle \rightarrow \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle$

$\langle \text{FAKTOR} \rangle \rightarrow (\langle \text{KIFEJEZÉS} \rangle)$

$\langle \text{FAKTOR} \rangle \rightarrow \langle \text{VÁLTOZÓ} \rangle$

$\langle \text{FAKTOR} \rangle \rightarrow \langle \text{KONSTANS} \rangle$

$\langle \text{VÁLTOZÓ} \rangle \rightarrow A$

$\langle \text{VÁLTOZÓ} \rangle \rightarrow B$

$\langle \text{VÁLTOZÓ} \rangle \rightarrow C$

$\langle \text{KONSTANS} \rangle \rightarrow 0$

$\langle \text{KONSTANS} \rangle \rightarrow 1$

1.1 példa: (egy aritmetikai kifejezés szintaxisának megadása)

2) Meg kell adni, hogy a már megadott szimbólumokból milyen szabályok alapján épülnek fel az aritmetikai kifejezések:

$$\langle \text{KIFEJEZÉS} \rangle \rightarrow \langle \text{TAG} \rangle \mid \langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle$$
$$\langle \text{TAG} \rangle \rightarrow \langle \text{FAKTOR} \rangle \mid \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle$$
$$\langle \text{FAKTOR} \rangle \rightarrow (\langle \text{KIFEJEZÉS} \rangle) \mid \langle \text{VÁLTOZÓ} \rangle \mid \langle \text{KONSTANS} \rangle$$
$$\langle \text{VÁLTOZÓ} \rangle \rightarrow A \mid B \mid C \mid D$$
$$\langle \text{KONSTANS} \rangle \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$$

Az 1.1 példában tehát **aritmetikai kifejezés**nek azokat az $A, B, C, D, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, +, *, (,)$ szimbólumokból álló jelsorozatokot (**szavakat** vagy **mondatokat**) fogjuk tekinteni, amelyek a fenti szabályok véges számú alkalmazásával felépíthetők.

Feladat: Vezessük le az $A * (B + 3)$ aritmetikai kifejezést!

$\langle \text{KIFEJEZÉS} \rangle \Rightarrow \langle \text{TAG} \rangle \Rightarrow \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle \Rightarrow \langle \text{TAG} \rangle * (\langle \text{KIFEJEZÉS} \rangle) \Rightarrow$
 $\Rightarrow \langle \text{TAG} \rangle * (\langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle) \Rightarrow \langle \text{TAG} \rangle * (\langle \text{TAG} \rangle + \langle \text{TAG} \rangle) \Rightarrow$
 $\Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{TAG} \rangle + \langle \text{TAG} \rangle) \Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{TAG} \rangle) \Rightarrow$
 $\Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow$
 $\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow$
 $\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{FAKTOR} \rangle)$

$\langle \text{KIFEJEZÉS} \rangle$	$\rightarrow \langle \text{TAG} \rangle \mid \langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle$
$\langle \text{TAG} \rangle$	$\rightarrow \langle \text{FAKTOR} \rangle \mid \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle$
$\langle \text{FAKTOR} \rangle$	$\rightarrow (\langle \text{KIFEJEZÉS} \rangle) \mid \langle \text{VÁLTOZÓ} \rangle \mid \langle \text{KONSTANS} \rangle$
$\langle \text{VÁLTOZÓ} \rangle$	$\rightarrow A \mid B \mid C \mid D$
$\langle \text{KONSTANS} \rangle$	$\rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$

Feladat: Vezessük le az $A * (B + 3)$ aritmetikai kifejezést!

$\langle \text{KIFEJEZÉS} \rangle \Rightarrow \langle \text{TAG} \rangle \Rightarrow \langle \text{TAG} \rangle + \langle \text{KIFEJEZÉS} \rangle$

$\Rightarrow \langle \text{TAG} \rangle * (\langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle)$

$\Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{TAG} \rangle + \langle \text{TAG} \rangle)$

$\Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{FAKTOR} \rangle)$

$\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow$

$\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow$

$\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{KONSTANS} \rangle) \Rightarrow$

$\Rightarrow A * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{KONSTANS} \rangle) \Rightarrow A * (B + \langle \text{KONSTANS} \rangle) \Rightarrow$

$\Rightarrow A * (B + 3)$

$\langle \text{KIFEJEZÉS} \rangle \rightarrow \langle \text{TAG} \rangle \mid \langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle$
 $\langle \text{TAG} \rangle \rightarrow \langle \text{FAKTOR} \rangle \mid \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle$
 $\langle \text{FAKTOR} \rangle \rightarrow (\langle \text{KIFEJEZÉS} \rangle) \mid \langle \text{VÁLTOZÓ} \rangle \mid \langle \text{KONSTANS} \rangle$
 $\langle \text{VÁLTOZÓ} \rangle \rightarrow A \mid B \mid C \mid D$
 $\langle \text{KONSTANS} \rangle \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$

Feladat: Vezessük le az $A * (B + 3)$ aritmetikai kifejezést!

$$\begin{aligned} \langle \text{KIFEJEZÉS} \rangle &\Rightarrow \langle \text{TAG} \rangle \Rightarrow \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle \Rightarrow \langle \text{TAG} \rangle * (\langle \text{KIFEJEZÉS} \rangle) \Rightarrow \\ &\Rightarrow \langle \text{TAG} \rangle * (\langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle) \Rightarrow \langle \text{TAG} \rangle * (\langle \text{TAG} \rangle + \langle \text{TAG} \rangle) \Rightarrow \\ &\Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{TAG} \rangle + \langle \text{TAG} \rangle) \Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{TAG} \rangle) \Rightarrow \\ &\Rightarrow \langle \text{FAKTOR} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow \\ &\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{FAKTOR} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow \\ &\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{FAKTOR} \rangle) \Rightarrow \\ &\Rightarrow \langle \text{VÁLTOZÓ} \rangle * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{KONSTANS} \rangle) \Rightarrow \\ &\Rightarrow A * (\langle \text{VÁLTOZÓ} \rangle + \langle \text{KONSTANS} \rangle) \Rightarrow A * (B + \langle \text{KONSTANS} \rangle) \Rightarrow \\ &\Rightarrow A * (B + 3) \end{aligned}$$

Az **1.1 példában** az aritmetikai kifejezés szintaxisa tehát a következőképpen definiálható:

Egy szó akkor és csakis akkor aritmetikai kifejezés, ha az $A, B, C, D, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, +, *, (,)$ szimbólumokból épül fel, és levezethető a $\langle \text{KIFEJEZÉS} \rangle$ -ből a megadott szintaktikai szabályok véges számú alkalmazásával.

A szintaxisnak ezt a megadási módját **generatív nyelvtannal** való szintaxis megadásnak nevezzük.

Egy **generatív nyelvtan** definíciójának tehát több dolgot is kell tartalmaznia:

- meg kell adni azokat a szimbólumokat, melyekből a definiálandó nyelv szavai fognak állni – ezek a **terminális szimbólumok**,
- meg kell adni azokat a szimbólumokat, amelyek ugyan nem fognak szerepelni az nyelvtan által generált nyelv szavai között, de szükségesek a szintaktikai szabályok megadásához – ezek a **nemterminális szimbólumok**,
- meg kell adni a **szintaktikai** (levezetési) **szabályokat**,
- meg kell adni azt a nemterminális szimbólumot, amelyből a definiálandó nyelv valamennyi szava levezethető – ez a **kezdő nemterminális szimbólum**.

1.2 példa: (egy egyszerű programozási nyelv szintaxisa)

$$N = \{ \langle \text{PROGRAM} \rangle, \langle \text{UTASÍTÁSLISTA} \rangle, \langle \text{UTASÍTÁS} \rangle, \langle \text{ÉRTÉKADÓ} \rangle, \\ \langle \text{IF UTASÍTÁS} \rangle, \langle \text{WHILE UTASÍTÁS} \rangle, \langle \text{BLOKK} \rangle, \langle \text{RELÁCIÓ} \rangle, \langle \text{RELÁCIÓJEL} \rangle, \\ \langle \text{KIFEJEZÉS} \rangle, \langle \text{TÁG} \rangle, \langle \text{FAKTOR} \rangle, \langle \text{VÁLTOZÓ} \rangle, \langle \text{KONSTANS} \rangle \}$$
$$\Sigma = \{ ., ;, :=, \text{IF}, \text{THEN}, \text{ELSE}, \text{WHILE}, \text{DO}, \text{BEGIN}, \text{END}, <, >, =, \neq, +, *, \\ (,), A, B, C, D, E, F, G, H, I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, \\ Z, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9 \}$$

1.2 példa: (egy egyszerű programozási nyelv szintaxisa)

$P: \langle \text{PROGRAM} \rangle \rightarrow \langle \text{UTASÍTÁSLISTA} \rangle.$

$\langle \text{UTASÍTÁSLISTA} \rangle \rightarrow \langle \text{UTASÍTÁS} \rangle \mid \langle \text{UTASÍTÁS} \rangle; \langle \text{UTASÍTÁSLISTA} \rangle$

$\langle \text{UTASÍTÁS} \rangle \rightarrow \langle \text{ÉRTÉKADÓ} \rangle \mid \langle \text{IF UTASÍTÁS} \rangle \mid \langle \text{WHILE UTASÍTÁS} \rangle \mid \langle \text{BLOKK} \rangle$

$\langle \text{ÉRTÉKADÓ} \rangle \rightarrow \langle \text{VÁLTOZÓ} \rangle := \langle \text{KIFEJEZÉS} \rangle$

$\langle \text{IF UTASÍTÁS} \rangle \rightarrow \text{IF } \langle \text{RELÁCIÓ} \rangle \text{ THEN } \langle \text{UTASÍTÁS} \rangle \text{ ELSE } \langle \text{UTASÍTÁS} \rangle$

$\langle \text{WHILE UTASÍTÁS} \rangle \rightarrow \text{WHILE } \langle \text{RELÁCIÓ} \rangle \text{ DO } \langle \text{UTASÍTÁS} \rangle$

$\langle \text{BLOKK} \rangle \rightarrow \text{BEGIN } \langle \text{UTASÍTÁSLISTA} \rangle \text{ END}$

$\langle \text{RELÁCIÓ} \rangle \rightarrow \langle \text{KIFEJEZÉS} \rangle \langle \text{RELÁCIÓJEL} \rangle \langle \text{KIFEJEZÉS} \rangle$

$\langle \text{RELÁCIÓJEL} \rangle \rightarrow < \mid > \mid = \mid \neq$

$\langle \text{KIFEJEZÉS} \rangle \rightarrow \langle \text{TAG} \rangle \mid \langle \text{KIFEJEZÉS} \rangle + \langle \text{TAG} \rangle$

$\langle \text{TAG} \rangle \rightarrow \langle \text{TAG} \rangle \mid \langle \text{TAG} \rangle * \langle \text{FAKTOR} \rangle$

$\langle \text{FAKTOR} \rangle \rightarrow (\langle \text{KIFEJEZÉS} \rangle) \mid \langle \text{VÁLTOZÓ} \rangle \mid \langle \text{KONSTANS} \rangle$

$\langle \text{VÁLTOZÓ} \rangle \rightarrow A \mid B \mid C \mid D \mid E \mid F \mid G \mid H \mid I \mid J \mid K \mid \dots \mid X \mid Y \mid Z$

$\langle \text{KONSTANS} \rangle \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$

1.3 példa: (az ALGOL60 programozási nyelvben használatos számok szintaxisa)

$$N = \{ \langle \text{szám} \rangle, \langle \text{előjel nélküli szám} \rangle, \langle \text{tizedes szám} \rangle, \langle \text{exponenciális rész} \rangle, \\ \langle \text{tizedes rész} \rangle, \langle \text{egész szám} \rangle, \langle \text{előjel nélküli egész szám} \rangle, \langle \text{számjegy} \rangle \}$$
$$\Sigma = \{ ., +, -, {}_{10}, 0, 1, 2, 3, 4, 5, 6, 7, 8, 9 \}$$

1.3 példa: (az ALGOL60 programozási nyelvben használatos számok szintaxisa)

P :

$$\langle \text{szám} \rangle \rightarrow \langle \text{előjel nélküli szám} \rangle \mid +\langle \text{előjel nélküli szám} \rangle \mid -\langle \text{előjel nélküli szám} \rangle$$
$$\langle \text{előjel nélküli szám} \rangle \rightarrow \langle \text{tizedes szám} \rangle \mid \langle \text{exponenciális rész} \rangle \mid$$
$$\langle \text{tizedes szám} \rangle \langle \text{exponenciális rész} \rangle$$
$$\langle \text{tizedes szám} \rangle \rightarrow \langle \text{előjel nélküli egész szám} \rangle \mid \langle \text{tizedes rész} \rangle \mid$$
$$\langle \text{előjel nélküli egész szám} \rangle \langle \text{tizedes rész} \rangle$$
$$\langle \text{exponenciális rész} \rangle \rightarrow {}_{10} \langle \text{egész szám} \rangle$$
$$\langle \text{tizedes rész} \rangle \rightarrow . \langle \text{előjel nélküli egész szám} \rangle$$
$$\langle \text{egész szám} \rangle \rightarrow \langle \text{előjel nélküli egész szám} \rangle \mid +\langle \text{előjel nélküli egész szám} \rangle \mid$$
$$-\langle \text{előjel nélküli egész szám} \rangle$$
$$\langle \text{előjel nélküli egész szám} \rangle \rightarrow \langle \text{számjegy} \rangle \mid \langle \text{számjegy} \rangle \langle \text{előjel nélküli egész szám} \rangle$$
$$\langle \text{számjegy} \rangle \rightarrow 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$$

1.3 példa: (az ALGOL60 programozási nyelvben használatos számok szintaxisa)

A $-.98_{10} - 06$ szám levezetése:

$$\begin{aligned} \langle \text{szám} \rangle &\Rightarrow -\langle \text{előjel nélküli szám} \rangle \Rightarrow -\langle \text{tizedes szám} \rangle \langle \text{exponenciális rész} \rangle \Rightarrow \\ &\Rightarrow -\langle \text{tizedes rész} \rangle \langle \text{exponenciális rész} \rangle \Rightarrow \\ &\Rightarrow -. \langle \text{előjel nélküli egész szám} \rangle \langle \text{exponenciális rész} \rangle \Rightarrow \\ &\Rightarrow -. \langle \text{számjegy} \rangle \langle \text{előjel nélküli egész szám} \rangle \langle \text{exponenciális rész} \rangle \Rightarrow \\ &\Rightarrow -.9 \langle \text{előjel nélküli egész szám} \rangle \langle \text{exponenciális rész} \rangle \Rightarrow \\ &\Rightarrow -.9 \langle \text{számjegy} \rangle \langle \text{exponenciális rész} \rangle \Rightarrow -.98 \langle \text{exponenciális rész} \rangle \Rightarrow \\ &\Rightarrow -.98_{10} \langle \text{egész szám} \rangle \Rightarrow -.98_{10} - \langle \text{előjel nélküli egész szám} \rangle \Rightarrow \\ &\Rightarrow -.98_{10} - \langle \text{számjegy} \rangle \langle \text{előjel nélküli egész szám} \rangle \Rightarrow \\ &\Rightarrow -.98_{10} - 0 \langle \text{előjel nélküli egész szám} \rangle \Rightarrow -.98_{10} - 0 \langle \text{számjegy} \rangle \Rightarrow \\ &\Rightarrow -.98_{10} - 06 \end{aligned}$$

Alapfogalmak

1.1 definíció: (ábécé)

Ábécének nevezzük szimbólumoknak egy tetszőleges véges, nem üres halmazát.

Megjegyzés: Az ábécét gyakran a görög Σ betűvel jelöljük (szigma).

1.2 definíció: (szó)

Legyen Σ egy ábécé. **Szó**nak nevezzük a Σ elemeiből képzett $a_1 a_2 \dots a_k$ alakú sorozatot, ahol $k > 0$ és $a_1, a_2, \dots, a_k \in \Sigma$.

Megjegyzés: Azt a szót, amelyre $k = 0$ teljesül, és ezért egyetlen Σ halmazbeli elemet sem tartalmaz, üres szóknak nevezzük és λ szimbólummal jelöljük.

1.4 példa: $\Sigma = \{A, B, C, D, E, F, G, H, I, J, K, L, M, N, O, P, Q, R, S, T, U, V, W, X, Y, Z\}$

A Σ ábécé elemeiből képzett szavak: COMPUTER, NYELV, ZXBKW

1.5 példa: $\Sigma = \{0,1,2,3,4,5,6,7,8,9\}$

A Σ ábécé elemeiből képzett szavak: 0, 254987, 777

1.6 példa: $\Sigma = \{0,1\}$

A Σ ábécé elemeiből képzett szavak: 0111011010, 111, 11010001

1.7 példa: $\Sigma = \{a,b\}$

A Σ ábécé elemeiből képzett szavak: *aabaabba*, *aaab*, *babbba*

1.8 példa: Legyen Σ az összes ASCII karakter halmaza.

A Σ ábécé elemeiből képzett szavak:]Ae*w2+/wq, @xa+#0_d, M\$%?

Σ^* – a Σ ábécé elemeiből képezhető összes szó halmaza

$$\Sigma^* = \{a_1 a_2 a_3 \dots a_k \mid a_1, a_2, a_3, \dots a_k \in \Sigma \wedge k \geq 0\}$$

Σ^+ – a Σ ábécé elemeiből képezhető összes nem üres szó halmaza

$$\Sigma^+ = \{a_1 a_2 a_3 \dots a_k \mid a_1, a_2, a_3, \dots a_k \in \Sigma \wedge k > 0\} = \Sigma^* \setminus \{\lambda\}$$

1.3 definíció: (szó hossza)

Egy w szó **hosszát** $|w|$ -vel jelöljük, s ez egyenlő a szavat alkotó szimbólumok számával, azaz $|w| = k$, ha $w = a_1 a_2 \dots a_k$.

Σ^n – a Σ ábécé elemeiből képezhető összes n hosszú szó halmaza

$$\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \dots \cup \Sigma^n \cup \dots \quad \Sigma^+ = \Sigma^1 \cup \Sigma^2 \cup \dots \cup \Sigma^n \cup \dots$$

1.4 definíció: (szavak egyenlősége)

A $w_1 = a_1 a_2 \dots a_k$ és $w_2 = b_1 b_2 \dots b_l$ szavak **egyenlők** ($w_1 = w_2$), ha $k = l$ és $a_i = b_i$, minden $i = 1, 2, \dots, k$ -ra.

1.5 definíció: (szavak konkatenációja)

Az $u, v \in \Sigma^*$ szavak **konkatenációján** a két szó összefűzésével, azaz egymás után történő leírásával kapott $uv \in \Sigma^*$ szót értjük.

Megjegyzés: Nyilvánvaló, hogy $|uv| = |u| + |v|$.

A konkatenáció művelet asszociatív, de nem kommutatív.

1.6 definíció: (szó k -adik hatványa)

A $w \in \Sigma^*$ szó **k -adik hatványán** k darab w szó konkatenációját értjük, és w^k -val jelöljük. Érvényes, hogy $w^0 = \lambda$.

1.7 definíció: (szó tükörképe)

A $w \in \Sigma^*$ szó visszafelé történő írását a w szó **tükörképének** nevezzük, és w^R -rel jelöljük.

Megjegyzés: Nyilvánvaló, hogy $(w^R)^R = w$ és $(uv)^R = v^R u^R$.

1.9 példa: Legyen $\Sigma = \{a, b\}$.

Az *abaab* szó hossza: $|abaab| = 5$

Az *abaab* és *bbab* szavak konkatenációja: *abaabbbab*

A *bbab* szó 3. hatványa: $bbab^3 = bbabbbabbbab$

Az *abaab* szó tükörképe: $abaab^R = baaba$

A Σ^* a köv. elemeket tartalmazza: $\Sigma^* = \{\lambda, a, b, aa, ab, ba, bb, aaa, \dots\}$

1.8 definíció: (formális nyelv)

A Σ^* halmaz valamely L részhalmazát **formális nyelv**nek nevezzük.

1.10 példa: A $\{00, 01001, 1101\}$ halmaz $\{0, 1\}$ ábécé feletti formális nyelv.

1.11 példa: A $\{\lambda, ab, aabb, aaabbb, \dots\}$ halmaz $\{a, b\}$ ábécé feletti formális nyelv.

Műveletek formális nyelvekkel

Mivel a nyelvek szavakat tartalmazó halmazok, ezért az ismert **halmazműveletek** elvégezhetők rajtuk:

- **egyesítés** – az $L_1 \cup L_2$ nyelv olyan szavakat tartalmaz, amelyek legalább az egyik nyelvbe beletartoznak,
- **metszet** – az $L_1 \cap L_2$ nyelv olyan szavakat tartalmaz, amelyek egyidejűleg mindkét nyelvbe beletartoznak,
- **különbség** – az $L_1 \setminus L_2$ nyelv olyan szavakat tartalmaz, amelyek az L_1 nyelvbe beletartoznak, de az L_2 nyelvbe nem,
- **komplementer** – az $\overline{L_1}$ nyelv olyan szavakat tartalmaz, amelyek nem tartoznak bele az L_1 nyelvbe.

Műveletek formális nyelvekkel

A nyelveken ezen kívül ún. **reguláris műveletek** is elvégezhetők:

- **konkatenáció** – az L_1 és L_2 nyelvek L_1L_2 konkatenációja olyan szavakat tartalmaz, amelyek L_1 nyelvbe tartozó szóval kezdődnek és L_2 nyelvbe tartozó szóval végződnek, azaz

$$L_1L_2 = \{uv \mid u \in L_1 \wedge v \in L_2\}$$

- **iteráció** – az L nyelv L^* iteráltja olyan szavakat tartalmaz, amelyeket az L nyelvbe tartozó tetszőleges számú szó konkatenációjával kapunk, azaz

$$L^* = \{\lambda\} \cup L \cup LL \cup LLL \cup \dots$$

1.12 példa: Legyen $L_1 = \{bb, a\}$ és $L_2 = \{a, ab, bbb\}$.

Ekkor $L_1L_2 = \{bba, bbab, bbbbb, aa, aab, abbb\}$

$L_1L_1L_1 = \{bbbbbb, bbbba, bbabb, abbbb, bbaa, abba, aabb, aaa\}$

$L_1^* = \{\lambda, bb, a, bbbb, bba, abb, aa, bbbbbb, bbbba, \dots\}$

Formális nyelvek megadása

Egy formális nyelv megadható

- szavainak felsorolásával $L_1 = \{ \lambda, 00, 1 \}$
 $L_2 = \{ a, aa, aaa, ab, ba, aba \}$
 $L_3 = \{ \lambda, ab, aabb, aaabbb, aaaabbbb, \dots \}$
- tulajdonság segítségével $L_4 = \{ a^n b^n ; n \geq 0 \}$
 $L_5 = \{ ww^R ; w \in \Sigma^* \}$
 $L_6 = \{ w \in \{a, b\}^* ; \#_a(w) = \#_b(w) \}$
- generatív nyelvtan segítségével.

1.9 definíció: (generatív nyelvtan)

Generatív nyelvtannak nevezzük a $G = (N, \Sigma, P, S)$ rendezett elemnégyest, ahol:

N egy ábécé, a **nemterminális ábécé**,

Σ egy ábécé, a **terminális ábécé**, $N \cap \Sigma = \emptyset$,

P az $\alpha \rightarrow \beta$ alakú **nyelvtani szabályok véges halmaza**, ahol $\alpha, \beta \in (N \cup \Sigma)^*$ és α tartalmaz legalább egy nemterminális szimbólumot,

S a **kezdő nemterminális szimbólum**, $S \in N$.

1.13 példa: A $G = (\{S, A\}, \{a, b\}, \{S \rightarrow aAb, aA \rightarrow aaAb, A \rightarrow \lambda\}, S)$ rendezett elemnégyes egy generatív nyelvtan.

1.10 definíció: (mondatforma)

A $w \in (N \cup \Sigma)^*$ szimbólumsorozatot **mondatformának** nevezzük.

1.11 definíció: (mondat, szó)

A $w \in \Sigma^*$ szimbólumsorozatot **mondatnak** v. **szónak** nevezzük.

Amennyiben egy $G = (N, \Sigma, P, S)$ nyelvtannak több olyan szabálya is van, melyeknek a bal oldala megegyezik, azaz pl. ha $\alpha \rightarrow \beta_1$, $\alpha \rightarrow \beta_2$, ..., $\alpha \rightarrow \beta_n$ az összes olyan P szabályhalmazbeli szabály, amelyeknek bal oldala α , akkor a továbbiakban ezt egyszerűbben így fogjuk írni:

$$\alpha \rightarrow \beta_1 \mid \beta_2 \mid \dots \mid \beta_n.$$

Ekkor a β_1 , β_2 , ..., β_n mondatformákat az α **alternatíváinak** nevezzük.

1.12 definíció: (közvetlen deriváció)

Az $(N \cup \Sigma)^*$ halmazon értelmezünk egy \Rightarrow_G -vel jelölt relációt, amelyet **közvetlen deriváció**nak (vagy *közvetlen levezetésnek*) nevezünk. Tetszőleges $\gamma, \delta \in (N \cup \Sigma)^*$ -ra $\gamma \Rightarrow_G \delta$ akkor és csak akkor áll fenn, ha $\gamma = \alpha_1 \alpha \alpha_2$ és $\delta = \alpha_1 \beta \alpha_2$, és $\alpha \rightarrow \beta \in P$.

Ilyenkor azt mondjuk, hogy a γ -ból az $\alpha \rightarrow \beta$ nyelvtani szabály alkalmazásával **deriválható** (levezethető) a δ .

A \Rightarrow reláció reflexív és tranzitív lezártját a \Rightarrow^* , míg tranzitív lezártját a \Rightarrow^+ jelöli.

A \Rightarrow^* relációt *derivációnak* vagy *levezetésnek* nevezzük.

A reláció n -edik hatványának definíciója szerint az $\alpha \Rightarrow^n \beta$ jelölés azt jelenti, hogy az α -ból kiindulva a P szabályhalmazbeli szabályok n -szeri alkalmazásával megkapható a β , azaz α -ból n lépésben deriválható (levezethető) β .

1.14 példa:

$$A \rightarrow aBBb \mid AaA$$

$$B \rightarrow \lambda \mid bCA$$

$$C \rightarrow AB \mid a \mid b$$

$$A \Rightarrow aBBb \Rightarrow abCABb \Rightarrow abCaBBbBb \Rightarrow abCaBbBb \Rightarrow abbaBbBb \Rightarrow \\ abbaBbb \Rightarrow abbabb$$

1.13 definíció: (generált nyelv)

A $G = (N, \Sigma, P, S)$ nyelvtan által **generált nyelv** az alábbi módon adható meg:

$$L(G) = \{w \in \Sigma^* \mid S \Rightarrow_G^* w\}.$$

1.14 definíció: (ekvivalens nyelvtanok)

A G_1 és G_2 generatív nyelvtanok, akkor és csakis akkor **ekvivalensek**, ha $L(G_1) = L(G_2)$.